Sistema de Automatização de Processos e Apoio à Identificação de Compostos em Análises Ômicas

João Pedro Benvenutti Vidal Cardoso
João Pedro Silva
Nyrx Oliveira de Aquino Farias

Universidade de Tecnologia e Automação - Campus Florianópolis (UniSENAI)
Rodovia, SC-401, 3730 - Saco Grande, Florianópolis - SC – Brasil, 88032-005

Projeto Aplicado | 3º Fase – Instituto SENAI de Tecnologia

joao_pb_cardoso@estudante.sesisenai.org.br
nyrxminmir@gmail.com
joao_silva26@estudante.sesisenai.org.br

Eixo Central: Automatização de Processo
e sistema de apoio a identificação

1. INTRODUÇÃO

A crescente geração de dados científicos em áreas como metabolômica e proteômica tem ampliado significativamente as possibilidades de investigação em química, biotecnologia e ciências ambientais. Essas áreas utilizam técnicas analíticas avançadas capazes de detectar e quantificar centenas ou milhares de compostos químicos presentes em diferentes matrizes biológicas ou ambientais. No entanto, embora os equipamentos e métodos de aquisição de dados tenham evoluído consideravelmente ao longo dos anos, o processamento e a interpretação dessas informações ainda representam um desafio importante, sobretudo devido ao grande volume de dados gerados e à complexidade das análises envolvidas.

Nesse contexto, o Instituto SENAI de Tecnologia (IST) Ambiental possui um setor de pesquisa responsável pela realização de análises metabolômicas e proteômicas, que geram grandes quantidades de dados analíticos. O fluxo de trabalho dessas análises é composto, de forma geral, por três etapas principais: a injeção da amostra no equipamento, a aquisição dos dados analíticos e o tratamento dos dados obtidos. Entre essas etapas, destaca-se o tratamento dos dados como uma fase crítica do processo, pois é nesse momento que ocorre a identificação de compostos químicos a partir dos sinais analíticos registrados pelos equipamentos.

De modo geral, cada sinal analítico obtido pode estar associado a diversos compostos químicos possíveis. Como consequência, os sistemas de análise geram listas contendo múltiplos candidatos para cada sinal identificado. Dessa forma, torna-se necessário avaliar individualmente cada um desses candidatos a fim de determinar qual composto apresenta maior plausibilidade dentro do contexto da análise realizada. Atualmente, essa etapa é

realizada predominantemente de forma manual pelos analistas. Para selecionar o composto mais provável, os profissionais consultam diferentes bases de dados científicas, analisam informações presentes na literatura especializada e verificam se a molécula faz sentido considerando a matriz analisada e o contexto experimental.

Esse procedimento, além de exigir elevado conhecimento técnico, demanda um tempo significativo da equipe responsável pelas análises. Como resultado, o processo torna-se repetitivo e, em muitos casos, pode limitar a escalabilidade das análises realizadas. Além disso, por depender fortemente da experiência e do conhecimento prévio de cada analista, a tomada de decisão pode apresentar variações entre diferentes profissionais, o que pode impactar a padronização das avaliações.

Apesar dessas dificuldades, observa-se que parte dos critérios utilizados pelos especialistas para avaliar os compostos candidatos já se encontra estruturada em tabelas e planilhas, frequentemente armazenadas em arquivos como planilhas eletrônicas. Essas informações incluem, por exemplo, dados relacionados à classificação química das moléculas, sua ocorrência em determinados organismos, bem como possíveis aplicações conhecidas. Paralelamente, diversas bases de dados científicas públicas disponibilizam informações relevantes sobre compostos químicos, entre as quais se destacam *PubChem, ChEBI, HMDB e FooDB*. Dessa forma, a integração dessas diferentes fontes de informação representa uma oportunidade significativa para a automação ou, ao menos, para a semi-automatização de etapas importantes do processo de análise.

Diante desse cenário, torna-se evidente a necessidade de desenvolver soluções baseadas em ciência de dados capazes de otimizar o fluxo de trabalho atualmente empregado. Nesse sentido, este projeto propõe o desenvolvimento de um pipeline de dados inteligente que permita automatizar etapas relacionadas à ingestão, processamento e análise de dados associados à identificação de compostos químicos. A proposta envolve a integração de múltiplas bases de dados, a utilização de dados previamente estruturados e a aplicação de modelos probabilísticos ou heurísticas de priorização, com o objetivo de reduzir o número de candidatos possíveis para cada sinal analítico.

Além disso, pretende-se disponibilizar visualizações analíticas e ferramentas de apoio à decisão que auxiliem os especialistas na avaliação dos resultados obtidos. Com a implementação dessa solução, espera-se reduzir significativamente o esforço manual atualmente necessário, bem como aumentar a consistência e a rastreabilidade das decisões tomadas ao longo do processo de identificação de compostos. Dessa forma, o sistema atuará como um mecanismo de apoio ao trabalho dos analistas, contribuindo para tornar o processo mais eficiente e escalável, ao mesmo tempo em que preserva o papel fundamental do julgamento científico especializado na validação final dos resultados.

2. JUSTIFICATIVA

A principal motivação deste projeto é resolver um gargalo operacional crítico identificado no setor de pesquisa do IST Ambiental. Atualmente, o processo de identificação de moléculas em análises de metabolômica e proteômica depende de um esforço manual exaustivo para cruzar informações geradas pelos equipamentos analíticos com dados disponíveis na literatura científica e em bases especializadas. Esse procedimento, além de demandar tempo significativo dos analistas, também pode aumentar a probabilidade de inconsistências ou perda de informações relevantes durante a triagem dos compostos candidatos. De acordo com *Dunn et al. (2013)*, o processamento e a interpretação de dados em larga escala representam um dos principais desafios para a escalabilidade de laboratórios analíticos modernos, uma vez que a conferência manual limita a capacidade de resposta a novas demandas e projetos de maior complexidade.

Outro aspecto fundamental para a viabilidade da solução proposta está relacionado à natureza dos dados envolvidos no processo analítico. As informações provenientes dos equipamentos (dados brutos), as planilhas contendo critérios técnicos de avaliação e os resultados obtidos a partir de bases externas são, em grande parte, dados semi-estruturados. Nesse contexto, conforme destacado por *Kim et al. (2021)*, o uso de APIs para acessar repositórios científicos, como o PubChem, possibilita a integração automatizada de grandes volumes de dados químicos, reduzindo erros de interpretação e garantindo maior consistência na análise das informações utilizadas durante o processo de identificação molecular.

Além disso, a aplicação de um sistema de priorização baseado em ranking de compatibilidade, fundamentado em probabilidade condicional, oferece uma base matemática consistente para o suporte à tomada de decisão. Em vez de depender exclusivamente de buscas manuais e análises isoladas, o sistema proposto utiliza heurísticas e critérios analíticos para indicar os candidatos mais plausíveis com base em evidências químicas disponíveis. Segundo *Degtyarenko et al. (2008)*, a integração de ontologias químicas, como as disponibilizadas pelo ChEBI, é essencial para padronizar a classificação de moléculas e estruturar o conhecimento químico em bases de dados. Dessa forma, o projeto contribui para aumentar a produtividade, a rastreabilidade e a confiabilidade das análises realizadas pelo laboratório, permitindo que os especialistas concentrem seus esforços na validação científica dos resultados obtidos.

3. ANÁLISE DE REQUISITOS

3.1 DEFINIÇÃO DE REQUISITOS FUNCIONAIS E NÃO FUNCIONAIS

Os requisitos funcionais detalham as ações diretas que o sistema deve realizar para automatizar a triagem de compostos, como integrar dados de múltiplas fontes e aplicar o ranking de compatibilidade. Já os requisitos não funcionais estabelecem os critérios de

qualidade e as limitações técnicas, garantindo que a solução seja desenvolvida em Python e opere como uma ferramenta de suporte, sem substituir o julgamento humano. Essa divisão é essencial para que o software não apenas execute as tarefas técnicas, mas atenda aos padrões de desempenho e rastreabilidade exigidos pelo IST.

3.2 REQUISITOS FUNCIONAIS (RF)

- ➔ **RF01 - Módulo de Ingestão de Dados Laboratoriais:** O sistema deve extrair sinais analíticos brutos (massa, tempo de retenção e intensidade) diretamente dos arquivos gerados pelos softwares Progenesis QI e MassLynx.
- ➔ **RF02 - Módulo de Enriquecimento via APIs Públicas:** A solução deve realizar consultas automatizadas às APIs do PubChem e ChEBI para coletar metadados químicos, estruturas SMILES e descrições das moléculas em um único fluxo de enriquecimento.
- ➔ **RF03 - Consolidação de Dados (Merge):** O software deve unificar automaticamente as tabelas de identificação e de abundância quantitativa, utilizando a coluna "Compound" como chave primária de ligação entre as fontes.
- ➔ **RF04 - Motor de Ranking Probabilístico:** Implementar uma lógica baseada em probabilidade condicional para priorizar os candidatos a compostos com base no *fragmentation score* e na similaridade isotópica fornecidos pelo equipamento.
- ➔ **RF05 - Classificação de Origem Molecular:** O sistema deve categorizar automaticamente se a molécula identificada é um produto natural (metabólito) ou um composto sintético com base nas informações das bases públicas.
- ➔ **RF06 - Mapeamento Taxonômico e Ontológico:** A ferramenta deve associar à molécula sua taxonomia (reino, família, gênero ou espécie) e sua classificação química (MeSH Tree ou ChEBI).
- ➔ **RF07 - Painel Interativo de Suporte à Decisão (Dashboard):** Desenvolver uma interface interativa (Streamlit) para que o analista químico visualize o ranking de compatibilidade e os dados de abundância de forma integrada.
- ➔ **RF08 - Módulo de Pré-processamento e Limpeza:** O sistema deve tratar automaticamente inconsistências, valores nulos e erros de tipagem provenientes das planilhas Excel e arquivos semi-estruturados.
- ➔ **RF09 - Mecanismo de Validação do Analista:** A interface deve permitir que o especialista aceite ou rejeite as sugestões de identificação do sistema, registrando a decisão final no dataset.
- ➔ **RF10 - Geração de Relatórios e Exportação:** O sistema deve exportar os resultados finais tratados (identificação + abundância) em formatos compatíveis com as necessidades do relatório técnico do IST.

3.3 REQUISITOS NÃO-FUNCIONAIS (RNF)

- ➔ **RNF01 - Pilha Tecnológica Padrão:** O projeto deve ser desenvolvido obrigatoriamente em Python (Ambiente Anaconda), utilizando VSCode para codificação e Git para controle de versão.
- ➔ **RNF02 - Estrutura de Persistência em Alta Performance:** Para o MVP, o sistema deve utilizar arquivos de alto desempenho (como Parquet) para garantir agilidade no cache das APIs e no carregamento do dashboard.
- ➔ **RNF03 - Eficiência no Processamento Analítico:** A solução deve reduzir significativamente o tempo de triagem manual, otimizando o fluxo de trabalho dos setores de pesquisa do IST.
- ➔ **RNF04 - Auditabilidade e Rastreabilidade do Ranking:** O sistema deve registrar e permitir a consulta de todos os critérios e pesos matemáticos aplicados para gerar a ordem de priorização dos compostos.
- ➔ **RNF05 - Interface de Apoio Científico:** O design da ferramenta deve focar em auxiliar a tomada de decisão, assegurando que o julgamento técnico final permaneça sob responsabilidade do analista humano.
- ➔ **RNF06 - Padronização e Rigor Matemático:** A automação deve assegurar que todos os sinais sejam avaliados sob a mesma lógica probabilística, eliminando variações subjetivas entre diferentes profissionais**.**

4. OBJETIVOS

4.1 OBJETIVO GERAL

Desenvolver um pipeline de dados inteligente capaz de automatizar a ingestão, integração e análise de informações químicas provenientes de múltiplas fontes, aplicando métodos de priorização baseados em ranqueamentos para auxiliar na identificação de compostos em análises metabolômicas e proteômicas e reduzir o esforço manual dos analistas.

4.2 OBJETIVOS ESPECÍFICOS

- ❖ **Integrar dados provenientes de múltiplas fontes:** Integração de Dados, incluindo dados analíticos laboratoriais, planilhas estruturadas e bases de dados químicas públicas, utilizando APIs e técnicas de web scraping para consolidar as informações

em um banco de dados unificado.

- **Desenvolver um modelo de priorização baseado em critérios probabilísticos ou heurísticos:** Desenvolver um modelo de ranqueamento que utilize parâmetros previamente definidos, como score de fragmentação, similaridade isotópica e outros indicadores analíticos. Esses critérios servirão como base para o cálculo de pontuações (scores), permitindo priorizar e ranquear os compostos candidatos associados aos sinais analíticos identificados.

- **Criar uma interface visual interativa:** Por meio de dashboards ou aplicações web, criar uma interface que permita aos analistas visualizar os resultados, explorar os dados e apoiar a tomada de decisão durante o processo de identificação de compostos químicos.

5. DIAGRAMAS (MAPA LÓGICO)

O diagrama entidade-relacionamento representa um sistema para organizar dados de experimentos de espectrometria de massas em estudos de metabolômica. A entidade Amostra descreve o material analisado no experimento, contendo informações como tipo de matriz e tempo de coleta. A partir das amostras são detectados Sinais Analíticos, que representam os picos observados no equipamento e possuem atributos como m/z, massa neutra e tempo de retenção. A entidade Abundância registra a intensidade de cada sinal em uma determinada amostra, funcionando como uma associação entre Amostra e Sinal Analítico.

Cada Sinal Analítico pode gerar uma ou mais Identificações, que correspondem a possíveis compostos responsáveis pelo sinal observado. Essas identificações incluem métricas como erro de massa, score de fragmentação, similaridade isotópica e score total. Cada identificação está associada a um Composto, que contém informações químicas como nome, fórmula molecular e massa neutra, e também a um Aduto, que indica a forma ionizada detectada no espectrômetro. Além disso, os compostos podem ser classificados em diferentes Classes Químicas, sendo essa relação representada pela entidade associativa Composto_Classe, permitindo que um composto pertença a múltiplas classes químicas.

Imagem 1: Diagrama Conceitual

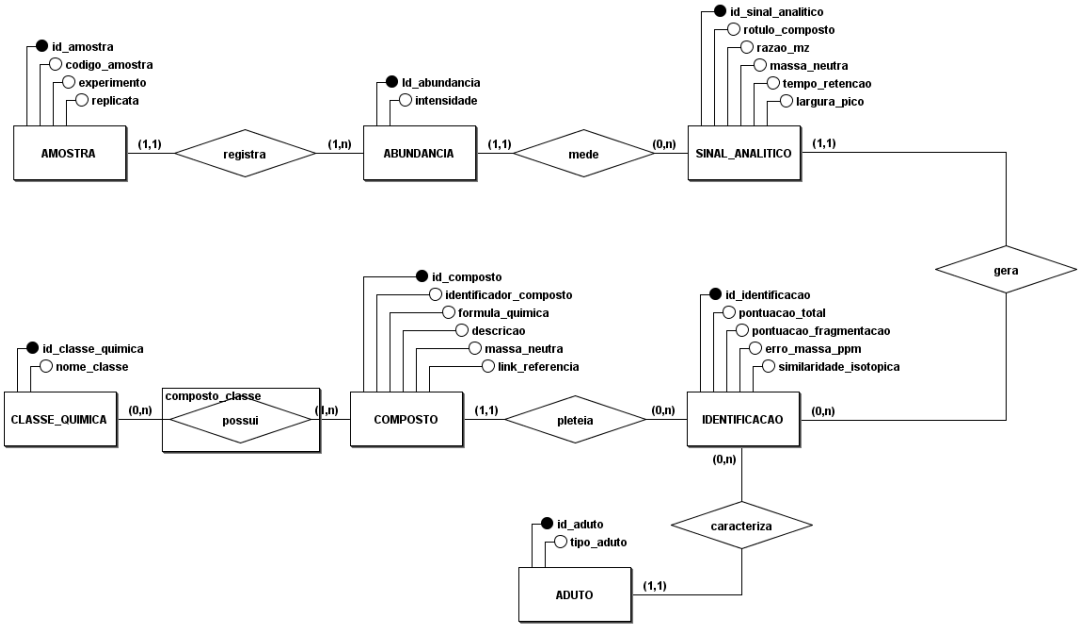

Fonte: Autoral

Imagem 2: Diagrama Lógico

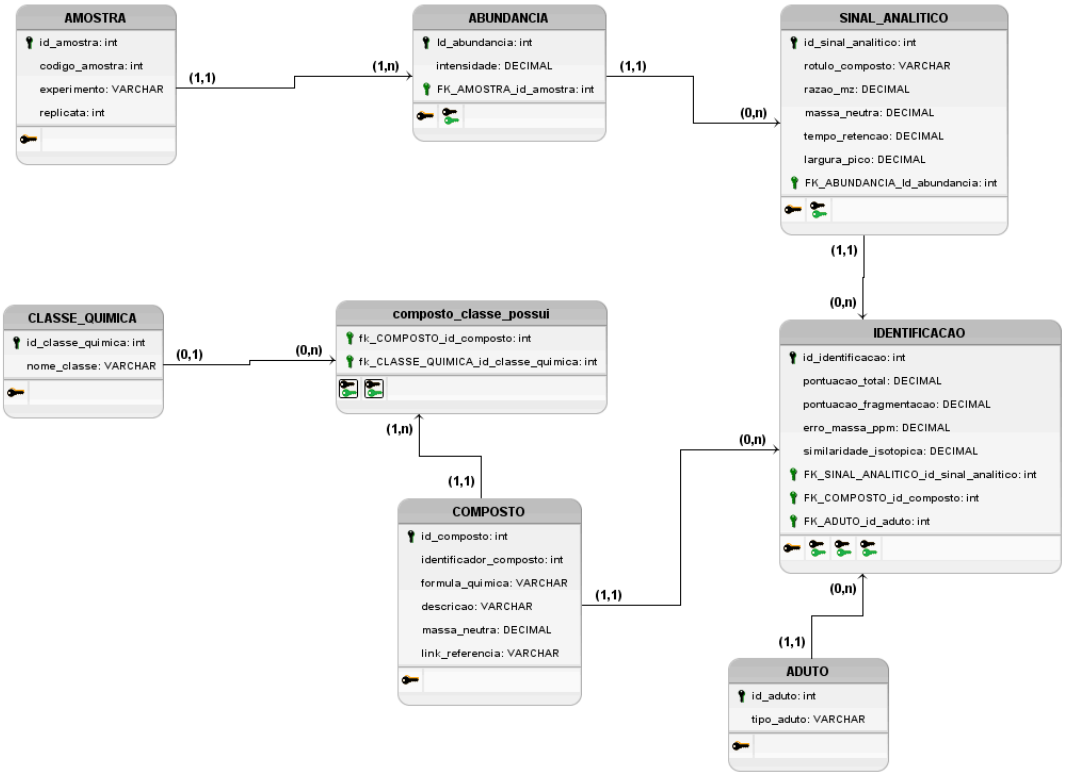

Fonte: Autoral

6. MAPA DE PROCESSO GERAL, WORKFLOW E COMPARAÇÃO COM OS PROCESSOS PASSADOS - JUNTOS E PARTE SEPARADO

6.1 ENTENDIMENTO DOS WORKFLOWS PROPOSTOS

6.1.1 Workflow Metabolômica

O processo de análise metabolômica inicia-se com a etapa de preparo das amostras, na qual é realizada a obtenção da fonte de metabólitos presentes no material biológico ou ambiental analisado. Nesse momento, são conduzidos procedimentos laboratoriais como secagem, extração dos metabólitos, centrifugação e, por fim, o preparo da amostra para a análise instrumental. Essas etapas são fundamentais, pois garantem que os compostos de interesse estejam adequadamente isolados e preparados para as fases seguintes do processo analítico.

Posteriormente, ocorre a etapa de separação, detecção e aquisição de dados, na qual os compostos presentes na amostra são separados por técnicas de cromatografia e analisados por espectrometria de massas em equipamentos do tipo QTOF. Durante essa fase, o sistema de aquisição registra os sinais analíticos gerados pelos compostos detectados, sendo gerenciados por softwares especializados, como MassLynx, que permitem o controle do equipamento e o armazenamento das informações geradas durante a análise.

Em seguida, inicia-se o processamento dos dados espectrais, etapa na qual os sinais obtidos são analisados utilizando abordagens como Data-Dependent Acquisition (DDA-MS) e ferramentas específicas de análise ômica, como Progenesis QI. Nesse momento, os sinais detectados são comparados com bases de dados químicas, entre as quais se destacam Human Metabolome Database e PubChem, possibilitando a geração de listas de compostos candidatos associados aos sinais analíticos. Posteriormente, os dados passam por análises computacionais, frequentemente realizadas em linguagens como Python, permitindo a exploração estatística dos resultados e a interpretação biológica dos metabólitos identificados.

Imagem 3: WorkFlow Metabolômica

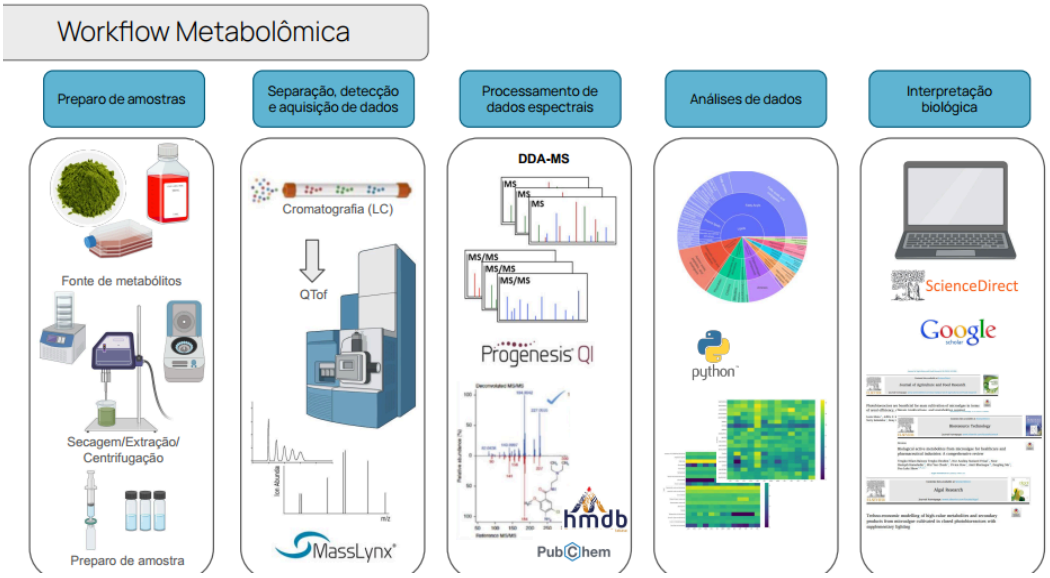

Fonte: ISI BLUMENAU - Workflow

6.1.2 Workflow Proteômica

De maneira semelhante à metabolômica, o fluxo de trabalho da proteômica também se inicia com o preparo das amostras, etapa na qual ocorre a extração das proteínas presentes no material analisado. Em seguida, é realizada a digestão proteica, processo responsável por fragmentar as proteínas em peptídeos menores, possibilitando sua análise por espectrometria de massas. Após essa digestão, a amostra passa por um processo de preparação final, garantindo que esteja adequada para a análise instrumental.

Na sequência, ocorre a etapa de separação, detecção e aquisição de dados, na qual os peptídeos são separados por cromatografia e posteriormente analisados por espectrometria de massas utilizando equipamentos do tipo QTOF. Durante essa fase, os dados gerados são registrados e gerenciados por softwares específicos de aquisição de dados, como MassLynx, que permitem monitorar o funcionamento do equipamento e armazenar os sinais analíticos produzidos durante a análise.

Por fim, os dados obtidos passam pela etapa de processamento e análise dos dados espectrais, frequentemente utilizando abordagens como Data-Independent Acquisition (DIA-MS) e ferramentas especializadas, como Progenesis QI. Nessa etapa, os sinais espectrais são comparados com bases de dados proteicas, como UniProt, permitindo a identificação e quantificação dos peptídeos e proteínas presentes na amostra. Posteriormente, os resultados podem ser analisados com ferramentas computacionais, incluindo scripts desenvolvidos em Python, os quais auxiliam na interpretação biológica e na exploração dos dados obtidos.

Imagem 3: WorkFlow Proteômica

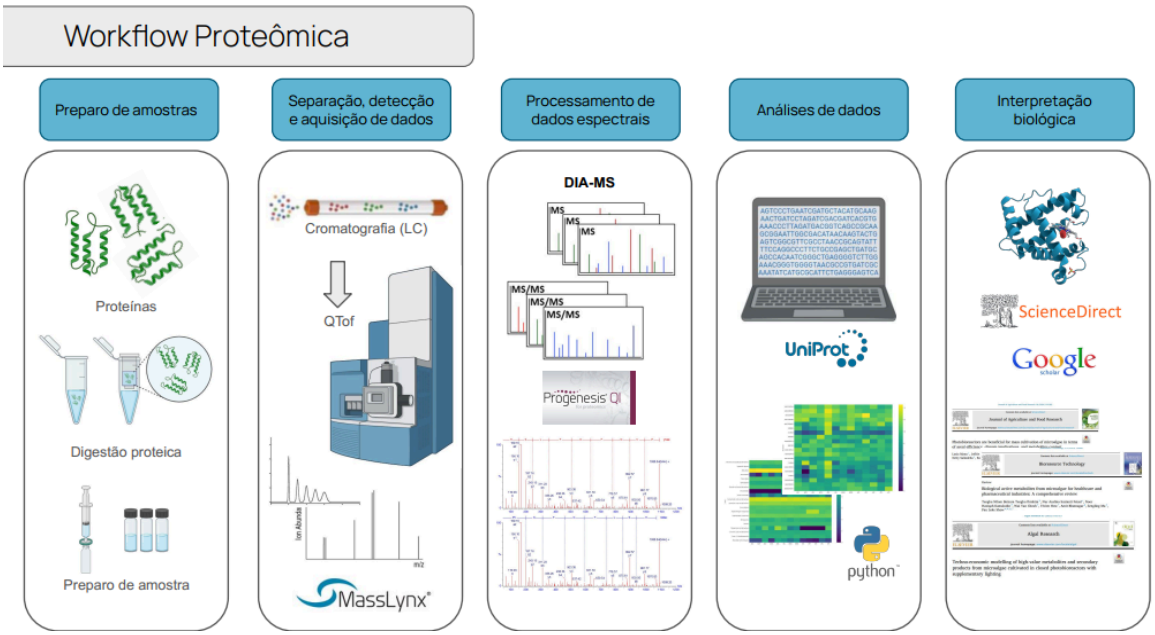

Fonte: ISI BLUMENAU - Workflow

6.2 ANÁLISE DE DADOS E INTERPRETAÇÃO BIOLÓGICA DO DESAFIO

Mapa de Processo Geral:

" 1. Entendimento dos dados → 2. Coleta e integração de dados → 3. Processamento e estruturação dos dados → 4. Desenvolvimento do modelo de priorização → 5. Desenvolvimento da interface visual → 6. Documentação final e apresentação do projeto "

Inicialmente será realizado o entendimento e a análise dos dados disponibilizados pelo laboratório, bem como das informações presentes nas bases de dados químicas que serão utilizadas no projeto. Nessa etapa também será elaborado um dicionário de dados, contendo a descrição das variáveis, parâmetros analíticos e demais informações relevantes para a compreensão e organização dos dados que serão utilizados ao longo do desenvolvimento da solução.

Em seguida, será desenvolvido o código responsável pela coleta e integração de informações provenientes de diferentes fontes de dados. Para isso, serão utilizadas APIs de bases de dados químicas e técnicas de web scraping, possibilitando a obtenção de informações complementares relacionadas à taxonomia, ontologia e propriedades associadas aos compostos químicos analisados. Após essa etapa de coleta, os dados obtidos serão submetidos a processos de limpeza, padronização e estruturação, garantindo que estejam organizados em um formato adequado para posterior análise e utilização no sistema.

Com os dados devidamente estruturados, será desenvolvido um modelo de priorização baseado em critérios analíticos previamente definidos, como score de fragmentação, similaridade isotópica e outros parâmetros relevantes. Esses critérios servirão como base para o cálculo de pontuações que permitirão ranquear os compostos candidatos associados aos sinais analíticos. Posteriormente, será desenvolvida uma interface visual utilizando a biblioteca Streamlit, permitindo que os analistas visualizem os resultados, explorem as informações obtidas e consultem o ranking de compostos gerado pelo sistema. Por fim, será elaborada a documentação final do projeto, descrevendo a metodologia adotada, as decisões técnicas realizadas, os resultados obtidos e as possíveis aplicações da solução desenvolvida, além da preparação da apresentação final do trabalho.

Imagem 4: WorkFlow Desafio - Ánalise de Dados e Identificação

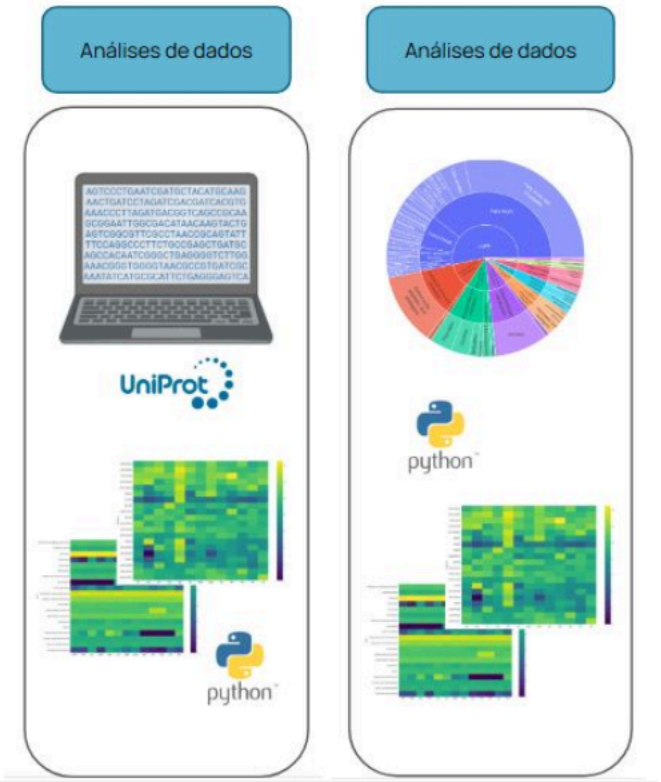

Fonte: ISI BLUMENAU - Workflow

6.3 INTEGRAÇÃO DOS WORKFLOWS E SUAS SIMILARIDADES E DIFERENÇAS

Os workflows de metabolômica e proteômica apresentados anteriormente apresentam estruturas analíticas semelhantes, uma vez que ambos são compostos por etapas fundamentais como preparo de amostras, separação e detecção por cromatografia acoplada à espectrometria

de massas, processamento de dados espectrais e, por fim, interpretação biológica dos resultados obtidos. No entanto, apesar dessas semelhanças estruturais, cada abordagem emprega estratégias específicas de aquisição e interpretação dos dados. Enquanto na metabolômica é frequentemente utilizada a abordagem DDA-MS, na proteômica destaca-se o uso de métodos baseados em DIA-MS. Além disso, cada área utiliza bases de dados distintas e especializadas para a identificação molecular dos compostos ou proteínas detectadas.

Adicionalmente, observa-se que, em ambos os fluxos analíticos, a etapa de processamento e interpretação dos dados representa um dos pontos mais complexos de todo o processo. Isso ocorre principalmente devido ao grande volume de dados espectrais gerados e à necessidade de realizar comparações com múltiplas bases de dados químicas e biológicas. Nesse contexto, surge o desafio abordado neste projeto, que consiste em organizar, integrar e priorizar as informações obtidas a partir dessas análises, de modo a auxiliar os especialistas no processo de identificação e interpretação dos compostos e proteínas detectados nas análises laboratoriais.

Dessa forma, a proposta desenvolvida neste trabalho busca atuar principalmente nas etapas finais dos workflows descritos, com foco no processamento, integração e interpretação dos dados gerados. Para isso, serão utilizadas técnicas computacionais voltadas à organização e análise de dados, além da integração com bases de dados externas. Paralelamente, será desenvolvida uma interface de visualização que possibilite aos analistas explorar as informações geradas e consultar os resultados de forma mais estruturada, contribuindo, assim, para uma análise mais eficiente e para o suporte à tomada de decisão pelos pesquisadores.

7. FERRAMENTAS

No desenvolvimento do projeto será utilizado um conjunto de ferramentas tecnológicas que auxiliarão tanto na implementação do sistema quanto no processamento e análise dos dados científicos. O desenvolvimento do sistema de análise ômica será realizado utilizando o Visual Studio Code como ambiente de desenvolvimento integrado (IDE), pois essa ferramenta permite a escrita, organização e manutenção eficiente do código. A linguagem de programação utilizada será Python, escolhida por sua ampla aplicação em ciência de dados e bioinformática. Além disso, o processamento e a análise dos dados serão realizados com o auxílio das bibliotecas Pandas, NumPy, Requests e Streamlit. Enquanto Pandas e NumPy serão responsáveis pela manipulação e análise numérica dos dados, Requests permitirá a comunicação com APIs externas, e Streamlit será utilizada para desenvolver interfaces web interativas, como dashboards, tabelas e visualizações que facilitarão a interpretação dos resultados pelos analistas.

Além disso, o sistema realizará a integração de dados provenientes de bases científicas especializadas por meio de APIs públicas, permitindo acessar informações relevantes sobre compostos químicos. Entre as principais bases de dados utilizadas

destacam-se PubChem, ChEBI e KEGG, que disponibilizam dados estruturados sobre propriedades químicas, classificações ontológicas e relações metabólicas das moléculas analisadas. A escolha dessas bases foi realizada com base em recomendações do professor Erick, considerando a relevância científica e a disponibilidade de recursos técnicos para integração de dados. O PubChem, por exemplo, disponibiliza uma API pública que permite acessar programaticamente informações químicas diretamente pelo sistema desenvolvido. Já o ChEBI fornece uma ontologia química estruturada, contendo classificações, taxonomia e relações entre compostos químicos. Por sua vez, o KEGG disponibiliza informações sobre vias metabólicas, aplicações biológicas e contextos bioquímicos das moléculas, contribuindo para ampliar a interpretação dos dados analisados.

Para a execução das atividades de desenvolvimento e análise serão utilizados computadores pessoais dos integrantes da equipe, equipados com sistemas operacionais compatíveis com Python e com capacidade suficiente de processamento, memória RAM e armazenamento para executar as rotinas de coleta, processamento e visualização de dados necessárias ao funcionamento do sistema. Dessa forma, a integração entre linguagem de programação, bibliotecas especializadas e bases de dados científicas permitirá a construção de uma solução capaz de apoiar de forma eficiente o processo de identificação de compostos em análises ômicas.

Paralelamente ao desenvolvimento técnico, serão utilizadas ferramentas voltadas à organização e documentação do projeto. A documentação do trabalho será elaborada por meio do Google Docs, permitindo a escrita colaborativa e o acompanhamento das contribuições de cada integrante do grupo. Da mesma forma, o Google Sheets será utilizado para análise complementar dos dados e para a elaboração do gráfico de Gantt, contribuindo para o planejamento e acompanhamento das etapas do projeto. Além disso, a plataforma Trello será empregada na organização das tarefas e no gerenciamento das atividades da equipe, garantindo que o andamento do trabalho permaneça alinhado com as necessidades e objetivos definidos para o projeto.

Por fim, a comunicação e o alinhamento entre os integrantes da equipe serão realizados por meio de ferramentas digitais que facilitam a colaboração e a organização das atividades do projeto. As reuniões e discussões ocorrerão através do Google Meet, possibilitando encontros virtuais para planejamento, tomada de decisões e acompanhamento do progresso das tarefas. Além disso, a comunicação rápida entre os membros do grupo será realizada por meio do WhatsApp, permitindo o compartilhamento ágil de informações, atualizações e dúvidas ao longo do desenvolvimento. Para a elaboração da apresentação final do projeto será utilizado o Canva, ferramenta que possibilita a criação de slides visuais e organizados, facilitando a apresentação dos resultados e das etapas do trabalho.

8. DIVISÃO DE EQUIPE

Para o desenvolvimento do projeto será adotada a metodologia ágil Scrum, pois se trata de uma abordagem amplamente utilizada em projetos de desenvolvimento de software que exigem flexibilidade, colaboração entre os integrantes e evolução gradual das funcionalidades do sistema. Nesse sentido, essa metodologia permite organizar o trabalho em ciclos curtos de desenvolvimento, conhecidos como sprints, nos quais são planejadas, desenvolvidas e avaliadas partes específicas da solução. Dessa forma, torna-se possível acompanhar continuamente o progresso do projeto, identificar possíveis dificuldades e realizar ajustes sempre que necessário ao longo do processo de desenvolvimento.

Além disso, para apoiar a organização das atividades e o acompanhamento das tarefas da equipe, será utilizada a plataforma Trello. Por meio dessa ferramenta será possível registrar as tarefas, definir prioridades e acompanhar o andamento das atividades de forma estruturada. Consequentemente, os integrantes poderão visualizar com maior clareza as responsabilidades de cada participante, bem como o progresso das entregas previstas em cada etapa do projeto, garantindo maior alinhamento e organização durante o desenvolvimento.

No que se refere à divisão das responsabilidades, a Nyrx será responsável principalmente pela documentação do projeto, realizando a organização dos registros das atividades, a elaboração de relatórios e a estruturação da documentação técnica e acadêmica. Por sua vez, João Benvenutti atuará nas áreas de programação e documentação, participando do desenvolvimento do sistema e da implementação das rotinas de integração de dados e interface visual interativa. Da mesma forma, João Silva também será responsável pelas atividades de programação e documentação, contribuindo para o desenvolvimento do pipeline de dados, para a implementação das funcionalidades do sistema e para o apoio na construção da interface visual. Assim, a divisão de tarefas entre os integrantes, aliada à aplicação da metodologia Scrum, permitirá que o projeto seja conduzido de forma organizada, colaborativa e eficiente, favorecendo o acompanhamento contínuo das atividades e a evolução gradual da solução proposta.

9. RELATÓRIO DE ENTREGÁVEIS

O relatório de entregáveis do projeto encontra-se atualmente em processo de construção e desenvolvimento. A elaboração está sendo realizada de forma contínua, acompanhando o workflow definido pelo grupo e respeitando as etapas previstas para o avanço das atividades de acordo com o plano discente. Além disso, o progresso do relatório está alinhado ao cronograma estabelecido para o projeto, garantindo que cada fase seja documentada conforme as tarefas são executadas. Dessa forma, o documento será atualizado progressivamente ao longo do desenvolvimento do trabalho, refletindo as decisões, resultados e ajustes realizados pela equipe. Ademais, o link encontra-se disponível no subtítulo acima.

10. OPORTUNIDADES DE MELHORIA

Embora o sistema proposto atenda aos objetivos iniciais do projeto, existem oportunidades de melhoria que podem ampliar suas funcionalidades e aumentar sua escalabilidade em versões futuras. Nesse contexto, uma possível evolução da solução seria o desenvolvimento de uma API própria, permitindo disponibilizar os dados processados e os resultados das análises de forma estruturada para outras aplicações ou sistemas. Dessa maneira, seria possível facilitar a integração com diferentes softwares utilizados no laboratório, além de possibilitar o reaproveitamento das funcionalidades desenvolvidas no pipeline de dados.

Além disso, outra melhoria relevante seria o desenvolvimento de uma interface de usuário mais robusta utilizando a biblioteca React. Atualmente, a interface proposta é voltada principalmente para a visualização rápida de informações; entretanto, a criação de um front-end dedicado permitiria construir uma aplicação web mais completa, oferecendo melhor organização das visualizações, maior interatividade com os dados e uma experiência de uso mais adequada para os analistas.

Assim, a adoção dessas melhorias contribuiria para tornar o sistema mais modular e preparado para futuras expansões. Consequentemente, a solução poderia ser utilizada por diferentes usuários e integrada a novos fluxos de trabalho dentro do ambiente de pesquisa, ampliando sua aplicabilidade e seu potencial de uso em análises científicas.

11. REFERÊNCIAS

ATKINS, Peter; JONES, Loretta. Princípios de química: questionando a vida moderna e o meio ambiente. 5. ed. Porto Alegre: Bookman, 2012.

BROWN, Theodore L. et al. Química: a ciência central. 13. ed. São Paulo: Pearson Education do Brasil, 2016.

DEGTYARENKO, K. et al. ChEBI: a database and ontology for chemical entities of biological interest. Nucleic Acids Research, Oxford, v. 36, n. supl. 1, p. D344–D350, 2008.

DUNN, W. B. et al. Procedures for large-scale metabolic profiling of serum and plasma using GC-MS and LC-MS. Nature Protocols, Londres, v. 6, n. 7, p. 1060–1083, 2011.

ELMASRI, Ramez; NAVATHE, Shamkant B. Sistemas de banco de dados. 6. ed. São Paulo: Pearson Education do Brasil, 2011.

HEUSER, Carlos Alberto. Projeto de banco de dados. 6. ed. Porto Alegre: Bookman, 2009.

HUMAN METABOLOME DATABASE. Human Metabolome Database. Disponível em: https://hmdb.ca. Acesso em: 8 mar. 2026.

INSTITUTO SENAI DE TECNOLOGIA. Instituto SENAI de Tecnologia (IST).

KIM, S. et al. PubChem in 2021: new data content and improved web interfaces. Nucleic Acids Research, Oxford, v. 49, n. D1, p. D1388–D1395, 2021.

OPENAI. ChatGPT. Disponível em: https://chat.openai.com. Acesso em: 8 mar. 2026.

PUBCHEM. PubChem Compound Database. Disponível em: https://pubchem.ncbi.nlm.nih.gov. Acesso em: 8 mar. 2026.

SCHWABER, Ken; SUTHERLAND, Jeff. Guia do Scrum: o guia definitivo para o Scrum. Disponível em: https://scrumguides.org/docs/scrumguide/v2020/2020-Scrum-Guide-Portuguese-Brazilian.pdf . Acesso em: 8 mar. 2026.

SCRUM GUIDES. The Scrum Guide. Disponível em: https://scrumguides.org. Acesso em: 8 mar. 2026.

SOCIEDADE BRASILEIRA DE QUÍMICA. Portal da Sociedade Brasileira de Química. Disponível em: https://www.sbq.org.br. Acesso em: 8 mar. 2026.